n-gram Language Model

Ki Hyun Kim

nlp.with.deep.learning@gmail.com



What is good model?

- Generalization
 - Training(seen) data를 통해서 test(unseen) data에 대해 훌륭한 prediction을 할 수 있는가?
- 만약 모든 경우의 수에 대해 학습 데이터를 모을 수 있다면, table look-up으로 모든 문제를 풀 수 있을 것
 - 하지만 그것은 불가능하므로 generalization 능력이 중요

Count based Approximation

Given sentence,

```
P(<\operatorname{BOS}>,\operatorname{I,love},\operatorname{to,play},<\operatorname{EOS}>) = P(<\operatorname{EOS}>|<\operatorname{BOS}>,\operatorname{I,love},\operatorname{to,play})P(<\operatorname{BOS}>,\operatorname{I,love},\operatorname{to,play})
= P(<\operatorname{EOS}>|<\operatorname{BOS}>,\operatorname{I,love},\operatorname{to,play})P(\operatorname{play}|<\operatorname{BOS}>,\operatorname{I,love},\operatorname{to})P(<\operatorname{BOS}>,\operatorname{I,love},\operatorname{to})
= P(<\operatorname{EOS}>|<\operatorname{BOS}>,\operatorname{I,love},\operatorname{to,play})P(\operatorname{play}|<\operatorname{BOS}>,\operatorname{I,love},\operatorname{to})P(\operatorname{to}|<\operatorname{BOS}>,\operatorname{I,love})P(<\operatorname{BOS}>,\operatorname{I,love})
= P(<\operatorname{EOS}>|<\operatorname{BOS}>,\operatorname{I,love},\operatorname{to,play})P(\operatorname{play}|<\operatorname{BOS}>,\operatorname{I,love},\operatorname{to})P(\operatorname{to}|<\operatorname{BOS}>,\operatorname{I,love})P(\operatorname{love}|<\operatorname{BOS}>,\operatorname{I})P(<\operatorname{BOS}>)
= P(<\operatorname{EOS}>|<\operatorname{BOS}>,\operatorname{I,love},\operatorname{to,play})P(\operatorname{play}|<\operatorname{BOS}>,\operatorname{I,love},\operatorname{to})P(\operatorname{to}|<\operatorname{BOS}>,\operatorname{I,love})P(\operatorname{love}|<\operatorname{BOS}>,\operatorname{I})P(\operatorname{I}|<\operatorname{BOS}>)P(<\operatorname{BOS}>)
```

We can approximate conditional probability by counting word sequence.

$$P(<\!\!\mathrm{EOS}>|<\!\!\mathrm{BOS}>,\mathrm{I,\,love,\,to,\,play}) \approx \frac{\mathrm{COUNT}(<\!\!\mathrm{BOS}>,\mathrm{I,\,love,\,to,\,play},<\!\!\mathrm{EOS}>)}{\mathrm{COUNT}(<\!\!\mathrm{BOS}>,\mathrm{I,\,love,\,to,\,play})}$$

• If we generalize this,

$$P(x_n|x_{< n}) pprox rac{ ext{COUNT}(x_1, \cdots, x_n)}{ ext{COUNT}(x_1, \cdots, x_{n-1})}$$



Problem of Count based Approximation

What if there is no such word sequence?

$$P(<\!\!\mathrm{EOS}>|<\!\!\mathrm{BOS}>,\mathrm{I,\,love,\,to,\,play}) \approx \frac{\mathrm{COUNT}(<\!\!\mathrm{BOS}>,\mathrm{I,\,love,\,to,\,play},<\!\!\mathrm{EOS}>)}{\mathrm{COUNT}(<\!\!\mathrm{BOS}>,\mathrm{I,\,love,\,to,\,play})}$$

Apply Markov Assumption

• Approximate with counting only previous k tokens.

$$P(x_n|x_{< n}) pprox P(x_n|x_{n-1}, \cdots, x_{n-k}) \ pprox rac{ ext{COUNT}(x_{n-k}, \cdots, x_n)}{ ext{COUNT}(x_{n-k}, \cdots, x_{n-1})}$$

• if
$$k = 2$$
,

$$P(x_n|x_{< n}) pprox P(x_n|x_{n-1},x_{n-2}) \ pprox rac{ ext{COUNT}(x_{n-2},x_{n-1},x_n)}{ ext{COUNT}(x_{n-2},x_{n-1})}$$

If we expand this to sentence level,

 Now, we can cover more word sequences, even if they are unseen in training corpus.

$$egin{aligned} \log P(x_{1:n}) &= \sum_{i=1}^n \log P(x_i|x_{< i}) \ &pprox \sum_{i=1}^n \log P(x_i|x_{i-1},\cdots,x_{i-k}) \end{aligned}$$

n-gram

•
$$n = k + 1$$

k	n-gram	명칭
0	1-gram	uni-gram
1	2-gram	bi-gram
2	3-gram	tri-gram

4-gram 부터는 그냥 four-gram...



n-gram

- n이 커질수록 오히려 확률이 정확하게 표현되는데 어려움
 - 적절한 n을 사용하자
- 보통은 3-gram을 가장 많이 사용
- corpus(말뭉치)의 양이 많을 때는 4-gram을 사용하기도
 - 언어모델의 성능은 크게 오르지 않는데 반해,
 - 단어 조합의 경우의 수는 exponential하게 증가하므로 효율성이 없음

How to Train/Inference n-gram LM?

- SRILM
 - download: http://www.speech.sri.com/projects/srilm/download.html



- ngram-count: LM을 훈련
 - o vocab: lexicon file name
 - o text: training corpus file name
 - o order: n-gram count
 - o write: output countfile file name
 - o unk: mark 00V as
 - \circ kndiscount n: Use Kneser-Ney discounting for N-grams of order n
- ngram: LM을 활용
 - o ppl: calculate perplexity for test file name
 - o order: n-gram count
 - o lm: language model file name



Summary

- 확률값을 근사하는 가장 간단한 방법은 코퍼스에서 <u>빈도를 세는 것</u>.
 - 하지만 복잡한 문장일수록 코퍼스에서 출현 빈도가 낮아, 부정확한 근사가 이루어질 것.
- 따라서 Markov assumption을 도입하여 확률값을 근사하자
 - 이제, 학습 코퍼스에서 보지 못한 문장에 대해서도 확률값을 구할 수 있다.
 - n의 크기가 중요함.
 - $n = 3 \sim 4$ 가 적당