# Smoothing and Discounting


Ki Hyun Kim

nlp.with.deep.learning@gmail.com



## **Smoothing**

- Markov assumption을 도입하였지만 여전히 문제는 남아있음
- Training corpus에 없는 unseen word sequence의 확률은 0?
- Unseen word sequence에 대한 대처
  - Smoothing or Discounting
- Popular algorithm
  - Modified Kneser-Ney Discounting



# **Add One Smoothing**

To prevent count becomes zero:

$$egin{split} P(w_t|w_{< t}) &pprox rac{\mathrm{C}(w_{1:t})}{\mathrm{C}(w_{1:t-1})} \ &pprox rac{\mathrm{C}(w_{1:t-1})}{\mathrm{C}(w_{1:t-1}) + |V|}, \end{split}$$

# Generalization of Add One Smoothing

• If we generalize this:

$$egin{aligned} P(w_t|w_{< t}) &pprox rac{\mathrm{C}(w_{1:t})}{\mathrm{C}(w_{1:t-1})} \ &pprox rac{\mathrm{C}(w_{1:t}) + 1}{\mathrm{C}(w_{1:t-1}) + |V|} \ &pprox rac{\mathrm{C}(w_{1:t-1}) + |V|}{\mathrm{C}(w_{1:t-1}) + k imes |V|} \ &pprox rac{\mathrm{C}(w_{1:t}) + rac{m}{|V|}}{\mathrm{C}(w_{1:t-1}) + m}, \end{aligned}$$

where |V| is a size of vocabulary.

• Take more generalization:

$$P(w_t|w_{< t}) pprox rac{\mathrm{C}(w_{1:t}) + m imes P(w_t)}{\mathrm{C}(w_{1:t-1}) + m},$$

where  $P(w_t)$  is unigram probability.

# **Kneser-Ney Discounting**

- In this lecture,
  - C(learning) > C(laptop)
  - Because of "deep learning", "machine learning"
- 다양한 단어 뒤에서 나타나는 단어일수록 unseen word sequence에 등장 할 확률이 높지 않을까?
  - 앞에 등장한 단어의 종류가 다양할 수록 해당 확률이 높을 것 같음

$$P_{continuation}(w) arpropto |\{v: C(v,w)>0\}|$$

# Summary

### Markov Assumption

- Count 기반의 approximation
- 긴 word sequence는 학습 코퍼스에 존재하지 않을 수 있음
  - 확률 값이 0으로 맵핑
- Markov assumption을 통해 근거리의 단어만 고려

### **Smoothing and Discounting**

- Markov assumption을 통해서도 여전히 확률 값이 0이 될 수 있음
- Smoothing 또는 discounting을 통해 현상을 완화
- 여전히 unseen word sequence에 대한 대처는 미흡