
Attention

Ki Hyun Kim

nlp.with.deep.learning@gmail.com



Previous Work





What is Attention?


- Differentiable Key-Value Function
- 기존의 Key-Value 함수와 달리, Query와 Key의 <u>유사도</u>에 따라 Value를 반환
- Decoder RNN(LSTM)의 <u>hidden state의 한계</u>로 인해 부족한 정보를 <u>직접 encoder에 조회</u>하여 예측에 필요한 정보를 얻어오는 과정
- 정보를 잘 얻어오기 위해 Query를 잘 만들어내는 과정을 학습

Attention in Seq2seq

- Query: 현재 time-step의 decoder output
- Keys: 각 time-step 별 encoder output
- Values: 각 time-step 별 encoder output




Intuitive Explanations



Encoder



Linear Transformation



Linear Transformation

• Example:



Google offered in: 한국어



Google offered in: 한국어

Q 강남역에서 가장 회식 하기 좋은 오리고기 맛있는 집은 어디야? Google Search I'm Feeling Lucky


Google Search I'm Feeling Lucky

> 마음의 상태(state)를 잘 반영하면서 좋은 검색 결과를 이끌어내는 쿼리를 얻기 위함



Before we start,

Batch Matrix Multiplication (BMM)



Equations

· With entire encoder's hidden states and current decoder's hidden state,

$$egin{aligned} w &= \operatorname{softmax}(h_t^{\operatorname{dec}} \cdot W_{\operatorname{a}} \cdot h_{1:m}^{\operatorname{enc}}) \ c &= w \cdot h_{1:m}^{\operatorname{enc}}, \end{aligned}$$


 $\text{where } c \in \mathbb{R}^{\text{batch_size} \times 1 \times \text{hidden_size}} \text{ is a context vector, and } W_{\text{a}} \in \mathbb{R}^{\text{hidden_size} \times \text{hidden_size}}.$

Re-define decoder's hidden state, and feed into generator,

$$egin{aligned} ilde{h}_t^{ ext{dec}} &= anh([h_t^{ ext{dec}}; c] \cdot W_{ ext{concat}}) \ & \hat{y}_t = ext{softmax}(ilde{h}_t^{ ext{dec}} \cdot W_{ ext{gen}}), \ \end{aligned}$$
 where $W_{ ext{concat}} \in \mathbb{R}^{(2 imes ext{hidden_size}) imes ext{hidden_size}} ext{ and } W_{ ext{gen}} \in \mathbb{R}^{ ext{hidden_size} imes |V|}.$




Attention





Evaluation





Summary

- Attention은 미분 가능한 Key-Value Function이다.
 - Attention 함수의 입력은 Query, Key, Value.
- 정보를 잘 얻기 위한 Query를 변환하는 방법을 배우는 과정
- Attention을 통해 RNN의 hidden state의 한계를 극복 가능
 - LSTM을 쓰더라도 context vector에 모든 정보를 담기에는 한계가 있음
 - 더 긴 길이의 입력/출력에도 대처할 수 있게 됨