Transformer: Multi-head Attention

Ki Hyun Kim

nlp.with.deep.learning@gmail.com



Attention: Query Generation

• Example:





Q 강남역에서 가장 회식 하기 좋은 오리고기 맛있는 집은 어디야?

Google Search I'm Feeling Lucky
Google offered in: 한국어

마음의 상태(state)를 잘 반영하면서

마음의 상태(state)를 잘 반영하면서 좋은 검색 결과를 이끌어내는 쿼리를 얻기 위함



Attention: Query Generation

• Example:





Q 강남역에서 가장 회식 하기 좋은 오리고기 맛있는 집은 어디야?



Q 강남역 오리고기 회식장소 맛집



Google Lear Pind 에 을 다양하게 할 수 oogle Searc Charles ing Pucky

Google offered in: 한국어

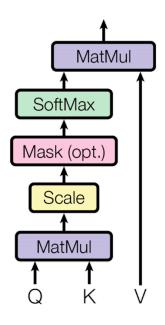
Google offered in: 한국어

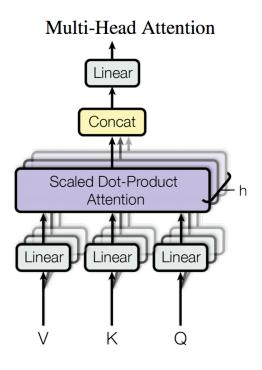
마음의 상태(state)를 잘 반영하면서 좋은 검색 결과를 이끌어내는 쿼리를 얻기 위함

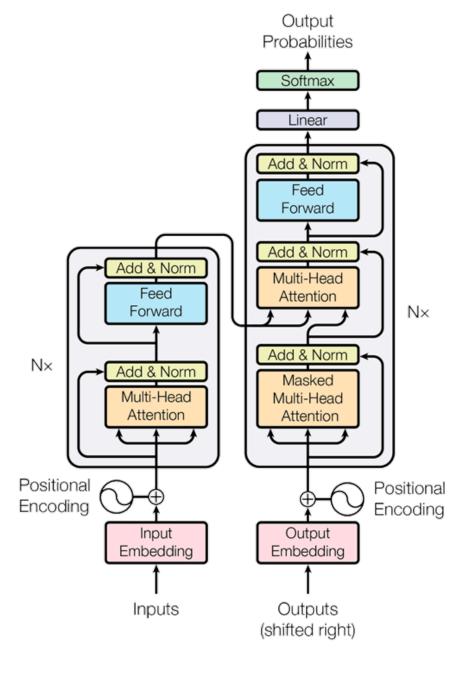


Transformer & Attention

Scaled Dot-Product Attention

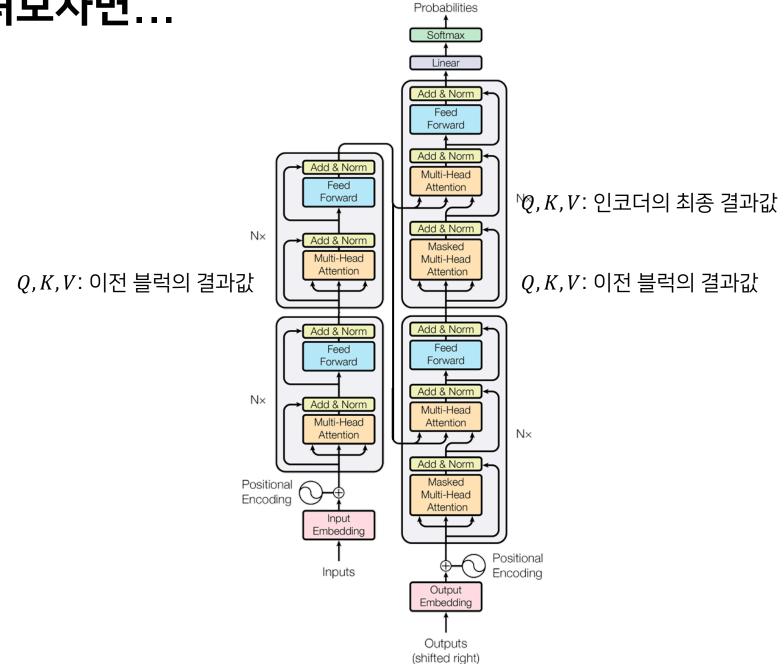








굳이 그려보자면...



Output

Equations

In case of Q, K and V come from same origin, $|Q| = |K| = |V| = (\text{batch_size}, n \text{ or } m, \text{hidden_size}).$

In case of Q and K, V come from different origin, $|Q| = (\text{batch_size}, n, \text{hidden_size})$ $|K| = |V| = (\text{batch_size}, m, \text{hidden_size}).$

$$\operatorname{Attention}(Q,K,V) = \operatorname{softmax}(rac{Q \cdot K^\intercal}{\sqrt{d_{\operatorname{head}}}}) \cdot V$$

 $\operatorname{MultiHead}(Q,K,V) = [head_1;\cdots;head_h]\cdot W^O$

$$ext{where } head_i = ext{Attention}(Q \cdot W_i^Q, K \cdot W_i^K, V \cdot W_i^V),$$

$$\text{and } W_i^Q \in \mathbb{R}^{d_{\text{model}} \times d_{\text{head}}}, W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_{\text{head}}}, W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_{\text{head}}}, W^O \in \mathbb{R}^{(h \times d_{\text{head}}) \times d_{\text{model}}}.$$

$$d_{
m head} = d_{
m model}/h = 64 \ h = 8, d_{
m model} = 512$$



Summary

- Previous method: attention in sequence to sequence
 - Query를 잘 만들어 key-value를 잘 matching 시키자
- Multi-head Attention
 - <u>여러 개의 query</u>를 만들어 다양한 정보를 잘 얻어오자
- Attention 자체로도 정보의 encoding과 decoding이 가능함을 보여줌

