# Introduction to Reinforcement Learning

Ki Hyun Kim


nlp.with.deep.learning@gmail.com



# RL의 구성

Agent, Environment, State, Action, Reward

#### Objective: Maximize expected cumulative reward



$$ext{episode} = \{s_0, a_0, r_1, s_1, a_1, r_2, s_2, a_2, r_3, s_3, a_3, \cdots \}$$




# Markov Decision Process (MDP)

#### **Markov Process**

• 상태의 이동 제약 조건에 이전 상태만 영향을 받는다.


$$P(s_t|s_{t-1})$$



#### **Markov Decision Process**

• 상태의 이동 제약 조건에 이전 상태와 행해진 액션에 영향을 받는다.

$$P(s_t|s_{t-1},a)$$





### **Cumulative Reward**


• Add all reward after t, until end of episode:

$$G_t = r_{t+1} + r_{t+2} + \cdots + r_T$$

Apply discount factor:

$$egin{aligned} G_t &= r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \cdots \ &= \sum_{k=0}^{\infty} \gamma^k r_{t+k+1} \end{aligned}$$

# Example: 가위, 바위, 보



# Policy and Value Function, Action-Value Function

Policy:

$$\pi(a|s) = P(A_t = a|S_t = s)$$

Value Function:

$$egin{aligned} v_\pi(s) &= \mathbb{E}_\pi[G_t|S_t = s] \ &= \mathbb{E}_\pi\Big[\sum_{k=0}^\infty \gamma^k r_{t+k+1} ig|S_t = s\Big], \ &orall s \in \mathcal{S}. \end{aligned}$$

Action-Value Function:

$$Q_\pi(s,a) = \mathbb{E}_\pi[G_t|S_t = s, A_t = a] = \mathbb{E}_\pi\Big[\sum_{k=0}^\infty \gamma^k r_{t+k+1} ig|S_t = s, A_t = a\Big], 
onumber \ orall s \in \mathcal{S} ext{ and } orall a \in \mathcal{A}.$$



# Summary

- RL Objective: Maximize expected cumulative reward,  $\mathbb{E}_{\pi}[G_t]$ 
  - 현재 상황에서 얻을 수 있는 누적 보상의 기대 값을 최대화
- Environment에 대한 정보가 부족하므로, 샘플링을 통해 value(or Q) function을 근사 하거나, policy 함수를 학습.
  - Value 기반의 방법과, Policy 기반의 방법으로 크게 나뉨
- 우리는 Policy 기반의 방법을 통해, NLG를 고도화 할 것